

ML4 - Kompresija ML modela

Luka Capan¹, Borna Budić¹, Silvia Petrović¹, Jakov Dragičević¹

Abstract—Duboke neuronske mreže (DNN) postižu izvanredne rezultate u zadacima klasifikacije slika, no njihova rastuća složenost otežava primjenu na uređajima s ograničenim resursima. Ovaj rad prikazuje praktičnu implementaciju cjelovite kompresijske cjevovode primijenjene na konvolucijsku neuronsku mrežu (CNN) treniranu od nule na skupu podataka Fruits-360 veličine 100x100 piksela. Cjevovod kombinira tri komplementarne tehnike: poboljšanu arhitekturu s BatchNorm i Dropout slojevima, dinamički pruning težina tijekom treniranja, te post-training kvantizaciju u INT8. Cijela implementacija ostvarena je isključivo u biblioteci NumPy, bez korištenja okvira za duboko učenje. Rezultati pokazuju da druga arhitektura postiže 77.55% top-1 točnosti na 261 klasi, što je poboljšanje od 5.25 postotnih bodova u odnosu na originalnu osnovicu (72.30%) uz 52% manje parametara. Primjena dinamičkog pruninga zadržava točnost od 77.45% pri 50% sparsity, a naknadna INT8 kvantizacija dodatno smanjuje teorijsku veličinu modela 4× uz pad točnosti od samo 0.05%. Konačni komprimirani model je 16.7× manji od originalne osnove uz istovremeno bolju točnost.

I. UVOD

Brzi napredak dubokog učenja proizveo je sve moćnije modele neuronskih mreža, no taj napredak dolazi po cijeni: moderne DNN-ove zahtijevaju značajne memorijske i računalne resurse koji često nisu dostupni na rubnim uređajima poput pametnih telefona, mikrokontrolera i FPGA-a [1]. Primjerice, ResNet-50 zahtijeva 98 MB pohrane i više od 3.8 milijarde operacija u pomičnom zarezu za obradu jedne slike.

Kompresija modela rješava ovaj problem smanjenjem veličine i računalne složenosti trenirane mreže uz zadržavanje što više predikcijske točnosti. Pregledni rad Li, Li i Meng [1] identificira pet glavnih obitelji tehnika kompresije: pruning težina, kvantizacija parametara, dekompozicija niskog ranga, distilacija znanja i dizajn lakih modela.

Cilj ovog rada je implementirati i evaluirati cjelovitu kompresijsku cjevovodu koja kombinira tri komplementarne tehnike: (i) arhitektonski dizajn s ugrađenom regularizacijom (Sekcija 4 pregleda), (ii) dinamički pruning težina (Sekcija 2.2 pregleda), te (iii) post-training kvantizaciju (Sekcija 3 pregleda). Implementacija koristi isključivo NumPy, čime svaka matematička operacija postaje eksplicitna i izravno povezana s jednadžbama iz preglednog rada.

Glavni doprinosi ovog rada su:

- Cjelovita implementacija CNN cjevovoda za treniranje u čistom NumPy-u, uključujući propagaciju unaprijed, propagaciju unatrag i SGD s momentumom.
- Poboljšana V2 arhitektura s BatchNorm i Dropout slojevima koja smanjuje broj parametara za 52%.

- Dinamički globalni nestrukturirani pruning težina po L1 magnitudi koji postupno povećava sparsity tijekom treninga.
- Post-training INT8 simetrična i asimetrična kvantizacija prema Algoritmu 1 i jednadžbama (1)–(5) iz [1].
- Kvantitativna usporedba točnosti, veličine modela i vremena inferencije kroz cijelu kompresijsku cjevovodu.

II. METODOLOGIJA

A. Arhitektura mreže — originalna osnovica

Polazna arhitektura, nazvana *SimpleCNN*, sastoji se od dva konvolucijska bloka iza kojih slijede dva potpuno povezana sloja:

- 1) **Conv1**: 8 filtara, jezgra 3×3 , padding 1 $\rightarrow$ ReLU $\rightarrow$ MaxPool 2×2
- 2) **Conv2**: 16 filtara, jezgra 3×3 , padding 1 $\rightarrow$ ReLU $\rightarrow$ MaxPool 2×2
- 3) **Flatten**: $(N, 16, 25, 25) \rightarrow (N, 10000)$
- 4) **FC1**: $10000 \rightarrow 128$, ReLU
- 5) **FC2**: $128 \rightarrow C$ (broj klasa), Softmax

Ulazne slike su RGB rezolucije 100×100 , normalizirane na $[0, 1]$. Ukupan broj parametara iznosi približno 1.32 milijuna, od čega 1.28 milijuna otpada na sloj FC1. He inicijalizacija primijenjena je na sve konvolucijske i potpuno povezane slojeve.

B. Poboljšana arhitektura

Analiza originalnog modela pokazala je značajan overfitting: točnost na treningu doseže približno 99% dok točnost na testu plateaua oko 72%. Razlika od približno 27 postotnih bodova ukazuje na to da model previše ovisi o memorizaciji trening skupa. Kako bi se ovaj problem riješio, dizajnirana je poboljšana arhitektura s tri konkretne izmjene:

- 1) **BatchNorm sloj nakon svake konvolucije** – normalizira aktivacije unutar batcha, stabilizira treniranje i djeluje kao blaga regularizacija [4].
- 2) **Dropout sa stopom $p = 0.3$ nakon FC1** – tijekom treniranja slučajno postavlja 30% aktivacija na nulu, sprječavajući FC1 da memorira pojedinačne primjere.
- 3) **Treći konvolucijski blok (16 $\rightarrow$ 32 filtera)** – dodaje dubinu i, kao posljedicu, treći MaxPool sloj koji smanjuje prostornu dimenziju s 25×25 na 12×12 . Time se ulaz u FC1 reducira s 10 000 na 4 608 značajki, a sam FC1 sa 1.28M na 590K parametara.

Poboljšana mreža ima ukupno 629 765 parametara, što je smanjenje od 52% u odnosu na originalnu. Javno sučelje drugog modela identično je prvom sučelju (forward, backward, get_trainable_layers), čime se osigurava da treninzi, pruning i kvantizacija rade bez izmjena ostatka koda.

¹Tehnički fakultet, Sveučilište u Rijeci, Hrvatska

C. Dinamički pruning težina

Implementiran je globalni nestrukturirani L1 pruning prema Han et al., kako je opisano u Sekciji 2.2 [1]. Za razliku od klasične paradigme *train* → *prune* → *fine-tune*, ovdje primijenjeni **dinamički pruning** postupno povećava sparsity tijekom treniranja prema rasporedu:

$$s(t) = s_{\text{final}} \cdot \left(1 - \left(1 - \frac{t - t_0}{t_1 - t_0}\right)^3\right) \quad (1)$$

gdje je $s(t)$ trenutna razina sparsity u epohi t , $s_{\text{final}} = 0.5$, $t_0 = 2$ (početna epoha), te $t_1 = 15$ (završna epoha). Kubična krivulja osigurava brži rast sparsity u prvim epohama, a usporavanje pri kraju.

Nakon svakog ažuriranja gradijentom, binarna maska se ponovno primjenjuje kako bi se osiguralo da pruned težine ostaju točno nula. Postupni pristup dopušta modelu da se prilagodi gubitku težina umjesto da iznenadno izgubi 50% kapaciteta.

D. Post-training kvantizacija

Implementirana je simetrična i asimetrična INT8 kvantizacija prema Algoritmu 1 i jednadžbama (1)–(5) [1]. Za svaki sloj zasebno računaju se faktor skale S i točka pomaka Z iz raspona težina $[R_{\min}, R_{\max}]$:

$$S = \frac{R_{\max} - R_{\min}}{Q_{\max} - Q_{\min}}, \quad Z = Q_{\max} - \frac{R_{\max}}{S} \quad (2)$$

Težine se zatim kvantiziraju u INT8:

$$Q = \text{round}\left(\frac{R}{S} + Z\right), \quad Q \in [-128, 127] \quad (3)$$

i dekvantiziraju natrag u FP32 za inferenciju:

$$\hat{R} = (Q - Z) \cdot S \quad (4)$$

Round-trip postupak FP32→INT8→FP32 omogućuje mjerenje utjecaja kvantizacije na točnost dok forward prolazi i dalje koristi FP32 aritmetiku. U stvarnoj hardverskoj implementaciji koja sprema težine kao INT8 (1 bajt umjesto 4), ovo daje teoretsko 4× smanjenje veličine modela.

III. EKSPERIMENTALNI POSTAV

A. Skup podataka

Korišten je *Fruits-360* [2], javno dostupan skup slika voća snimljenih nad bijelom pozadinom. Svaka slika je rezolucije 100×100 piksela u RGB formatu. Korištena verzija sadrži 261 različitu klasu voća i povrća.

Za eksperimente korišteno je 100 slika po klasi za treniranje i potpuni test skup za evaluaciju (približno 26 016 trening i 25 244 test slika). Slike su normalizirane na $[0, 1]$ dijeljenjem vrijednosti piksela s 255. Nije primijenjena augmentacija podataka.

B. Tijek eksperimenta

Cjelovita kompresijska cjevovoda izvodi se u tri koraka:

- 1) **Treniranje s dinamičkim pruningom**: SimpleCNNv2 trenira se 15 epoha s $\eta = 0.01$, batch size 32, momentum 0.9. Pruning počinje u 2. epohi i postupno postiže 50% sparsity do 15. epohe.
- 2) **Kvantizacija**: učitava se najbolji checkpoint iz koraka 1, a zatim se primjenjuje asimetrična INT8 PTQ sloj po sloj.
- 3) **Evaluacija**: točnost se mjeri na potpunom test skupu nakon svakog koraka.

Cjevovod je pokrenut na laptopu s 16 GB RAM-a bez GPU akceleracije. Ukupno trajanje pravog runa iznosi približno 5 sati i 30 minuta.

IV. REZULTATI I RASPRAVA

A. Usporedba arhitektura modela

Tablica I prikazuje rezultate usporedbe modela arhitektura pod identičnim uvjetima treniranja (isti seed, isti dataset, 10 epoha, 100 slika po klasi).

TABLE I
USPOREDBA MODELA ARHITEKTURE POD IDENTIČNIM UVJETIMA.

Metrika	Original	Poboljšana
Top-1 točnost (%)	72.30	77.55
Broj parametara	1 315 189	629 765
Veličina modela (KB)	10 275	4 920
Vrijeme inferencije (ms)	82.30	89.14
Vrijeme treninga	2h 34min	3h 16min
Promjena točnosti	—	+5.25%
Promjena broja parametara	—	−52.1%

Poboljšana arhitektura postiže poboljšanje od 5.25 postotnih bodova u točnosti uz istovremeno smanjenje broja parametara za 52.1%. Iako je inferencija 8.3% sporija zbog BatchNorm operacija, a trening 27% duži zbog dodatnog konvolucijskog sloja, oba ova troška su jednokratna i prihvatljiva za poboljšanje generalizacije.

B. Dinamički pruning na poboljšanom modelu

Tablica II prikazuje napredak treninga s dinamičkim pruningom kroz 15 epoha.

TABLE II
NAPREDAK DINAMIČKOG PRUNINGA TIJEKOM TRENIRANJA V2
MODELA.

Epoha	Gubitak	Točnost (%)	Sparsity (%)
1	5.04	9.39	0.00
3	1.95	64.25	18.44
5	0.94	71.73	31.75
7	0.60	74.31	40.67
10	0.36	75.89	47.72
12	0.27	76.81	49.50
14	0.23	77.45	49.98
15	0.20	77.26	50.00

Najbolji model postignut je u 14. epohi s 77.45% točnosti pri sparsity od 49.98%. Bitno je primijetiti da pruning praktički nije naštetio točnosti: poboljšani bez pruninga postiže 77.55%, a poboljšani s 50% pruningom 77.45% — razlika od samo 0.10 postotnih bodova. Postupna priroda dinamičkog pruninga omogućila je modelu da se prilagodi gubitku težina umjesto da podnese iznenadnu redukciju kapaciteta.

C. Konačna kompresija s kvantizacijom

Nakon kvantizacije pruned poboljšanog modela u INT8, dobiveni su rezultati prikazani u Tablici III.

TABLE III
REZULTATI INT8 KVANTIZACIJE PRIMIJENJENE NA PRUNED
POBOLJŠANI MODEL.

Metrika	Pruned V2 (FP32)	Quantizirano (INT8)
Točnost (%)	76.53	76.48
Veličina (KB)	4 920	614.5 (teor.)
Vrijeme inferencije (ms)	87.36	73.60
Pad točnosti	—	0.05%
Ubrzanje	—	1.19×

INT8 kvantizacija postiže teorijsko 4× smanjenje veličine modela uz zanemariv pad točnosti od 0.05%. Mjereno ubrzanje inferencije od 1.19× posljedica je smanjenog dinamičkog raspona težina nakon kvantizacije.

D. Cjelovita usporedba: Modeli → Pruning → Kvantizacija

Tablica IV prikazuje konačnu usporedbu svih faza kroz cijelu kompresijsku cjevovodu.

TABLE IV
CJELOVITA USPOREDBA SVIH FAZA KOMPRESIJE U ODNOSU NA V1
(ORIGINALNU) OSNOVICU.

Faza	Točnost (%)	Veličina (KB)	Faktor
V1 osnovica (KT1)	72.30	10 275	1.0×
V2 (BN + Dropout)	77.55	4 920	2.1×
V2 + Pruning	77.45	2 460*	4.2×
V2 + Pruning + INT8	76.48	614.5	16.7×

*Efektivna veličina uz 50% nula u težinama.

Konačni komprimirani model je **16.7×** manji od originalne V1 osnove, dok istovremeno postiže **4.18 postotnih bodova bolju točnost** (76.48% vs 72.30%). Ovaj rezultat pokazuje da dobro projektirana kombinacija arhitektonskog dizajna i tehnika kompresije može istovremeno poboljšati i sažeti model, što je u skladu s preporukama iz pregleda [1].

E. Per-layer analiza kvantizacijske greške

Prosječna greška kvantizacije po sloju (srednja apsolutna razlika između originalnih i dekvantiziranih težina) ostala je ispod 0.003 za sve slojeve. Najmanja greška opažena je u sloju FC1 (0.000377), što potvrđuje da je 256-razinska INT8 rešetka više nego dovoljno fina za distribucije težina opažene u potpuno povezanim slojevima.

V. ZAKLJUČAK

Ovaj rad prikazao je cjelovitu kompresijsku cjevovodu za CNN modele implementiranu u čistom NumPy-u, kombinirajući tri komplementarne tehnike opisane u pregledu Li, Li i Meng [1].

Glavni rezultati su sljedeći. Poboljšana arhitektura s Batch-Norm i Dropout slojevima postigla je 77.55% top-1 točnosti uz 52% manje parametara od originalne osnove. Dinamički L1 pruning sa 50% sparsity zadržao je točnost na 77.45% (pad od samo 0.10 postotnih bodova). Post-training INT8 kvantizacija ostvarila je teorijsko 4× smanjenje veličine uz pad točnosti od 0.05% i ubrzanje inferencije od 1.19×

Kombinacija sve tri tehnike daje finalni model koji je 16.7× manji od originalne osnove uz istovremeno 4.18 postotnih bodova *bolju* top-1 točnost. Time je pokazano da pažljivim arhitektonskim dizajnom u kombinaciji s dinamičkim pruningom i INT8 kvantizacijom moguće postići značajnu kompresiju bez ikakvog značajnog gubitka prediktivne sposobnosti.

REFERENCES

- [1] Z. Li, H. Li, and L. Meng, „Model Compression for Deep Neural Networks: A Survey,” *Computers*, vol. 12, no. 3, p. 60, ožujak 2023. <https://doi.org/10.3390/computers12030060>
- [2] H. Mureşan and M. Oltean, „Fruit recognition from images using deep learning,” *Acta Universitatis Sapientiae, Informatica*, vol. 10, br. 1, str. 26–42, 2018.
- [3] S. Han, J. Pool, J. Tran, and W. Dally, „Learning both weights and connections for efficient neural network,” u *Proc. NeurIPS*, Montreal, QC, Kanada, 2015, str. 1135–1143.
- [4] S. Ioffe and C. Szegedy, „Batch normalization: Accelerating deep network training by reducing internal covariate shift,” u *Proc. ICML*, Lille, Francuska, 2015, str. 448–456.
- [5] M. Nagel, M. Fournarakis, R. A. Amjad, Y. Bondarenko, M. van Baalen, and T. Blankevoort, „A white paper on neural network quantization,” *arXiv preprint arXiv:2106.08295*, 2021.