




ML4 - KOMPRESIJA ML MODELA


TEHNIČKI FAKULTET u Rijeci

Sveučilišni diplomski studij računarstva

Sudionici: Jakov Dragičević, Silvia

Petrović, Luka Capan, Borna Budić

KOMPRESIJA NEURALNIH MREŽA



- Napredni DNN modeli su postali kompleksni
- Rezultat je velika memorijska potrošnja i visokim zahtjevima za računanjem
- Model definira CNN arhitekturu - temelj cijelog pipeline-a

USPOREDBA MODELA

Model	Slojevi	Parametri	FLOPs	Top-1 greška
AlexNet	8	233MB	4.4G	43.45%
GoogLeNet	22	51MB	8.9G	34.20%
VGGNet-16	16	528MB	15.5G	27.30%
ResNet-50	50	98MB	17.9G	24.60%
ResNet-152	152	230MB	49.1G	23.00%
SENet-154	154	440MB	93.8G	18.68%

FLOPs mjereni za sliku 512x512 | Parametri u FP32 formatu | Izvor: Tablica 1, stranica 2

METODE KOMPRESIJE MODELA

Model Pruning

Uklanjanje nevažnih slojeva/kanala bez velikog utjecaja na performanse

Parameter quantization

Pretvorba float izračuna u nisko-bitne int operacije (FP32 → INT8)

Low-rank decomposition

Aproksimacija matrice težina pomoću tenzorske dekompozicije

Knowledge distillation

Veliki teacher model trenira manji student model na sličnu razinu točnosti

Lightweight design

Specijalne konvolucijske strukture smanjuju parametre i računanje (MobileNet)

STRUCTURED PRUNING (1/2)

Kako funkcionira?

1. Evaluacija važnosti svakog kanala
2. Kanali s manjim doprinosom dobivaju niži score
3. Nevažni kanali se ukanjaju iz sloja
4. Odgovarajući kanali u susjednim slojevima se također uklanjaju
5. Model se fine-tune-a kako bi se oporavila točnost

Ključne metode (str. 4-5)

Li et al.: Suma apsolutnih težina kao mjere važnosti kanala

Lin et al.: Globalna diskriminantna funkcija + dinamično obavljanje pogrešno odrezanih kanala

Liu et al.: Network Slimming – L1 regularizacija na BN sloju (iterativni pruning)

Yang et al.: Energy-aware pruning – minimizacija greške feature mape umjesto filter težina

Chen et al.: OTO (Only Train Once) - jedan prolaz, bez višestrukog fine-tuning-a

STRUCTURED PRUNING (2/2)

Prednosti

- Sužava mrežu → direktna hardverska akceleracija
- Nema potrebe za sparse konvolucijskim bibliotekama
- Reducira vrijeme računanja (posebno vidljivo u dubokim mrežama)
- Komprimira model do proizvoljnog stupnja
- Moguće kombinirati s distilizacijom i kvantizacijom

Nedostaci

- Structured pruning uzrokuje pad točnosti modela
- Teško automatski odrediti optimalni prag rezanja
- Potrebno višestruko fine-tuning (osim OTO metode)
- Različiti slojevi trebaju različite pragove — globalni pristup nije trivijalan
- Performanse ovise o arhitekturi mreže

UNSTRUCTURED PRUNING (1/2)

Kako funkcionira?

- Uklanja pojedinačne težine umjesto cijelih struktura
- Temelji se na prepoznavanju nevažnih parametara u mreži
- Dobiva se rijetka (sparse) mreža
- Cilj je smanjiti veličinu modela i izračune uz očuvanje točnosti

Kako se procjenjuje važnost?

- Magnituda težine (manje vrijednosti → manje važne)
- Metode temeljene na gradijentima
- Hessian (drugi derivacijski podaci)

UNSTRUCTURED PRUNING (2/2)

Tipični pristupi

- Optimal Brain Damage: uklanja težine s najmanjim utjecajem na gubitak
- Train-prune-retrain:
 - treniranje punog modela
 - uklanjanje malih težina
 - ponovno treniranje za oporavak točnosti

Prednosti

- Visok stupanj kompresije
- Može zadržati točnost nakon ponovnog treniranja
- Značajno smanjenje broja parametara

Nedostaci

- Stvara nepravilnu rijetkost (irregular sparsity)
- Teško se hardverski akcelerira
- Nulte težine ostaju u strukturi
- Slaba kompatibilnost s modernim hardverom

KVANTIZACIJA PARAMETARA

- **Kako funkcionira?** Smanjuje preciznost težina i aktivacijskih vrijednosti
- **Glavna ideja:** pretvorba iz floating-point (FP32) u niskobitne vrijednosti (npr. INT8)
- **Zašto funkcionira?** Neuronske mreže toleriraju male numeričke aproksimacije
- **Prednosti:**
 - manja memorijska potrošnja
 - brže izvođenje (inferencija)
 - manja potrošnja energije
- **Primjena:** često se koristi na mobilnim i edge uređajima

PROCES I KONCEPT KVANTIZACIJE

Koraci kvantizacije

1. Određivanje minimalne i maksimalne vrijednosti
2. Odabir tipa: simetrična/asimetrična
3. Izračun skale (S) i nulte točke (Z)
4. Pretvorba u nisku preciznost
5. Evaluacija performansi

Ključni koncept

- Mapiranje između floating-point i fiksno-točkastih vrijednosti

Važan kompromis

- Manja preciznost → veća učinkovitost
- Mogući gubitak točnosti

KVANTIZACIJA UZ UČENJE

QAT (Quantization-Aware Training)

- Kvantizacija se simulira tijekom treniranja
 - Primjenjuje se u: forward prolazu i backward prolazu
-
- **Zašto je potrebna?** Kvantizacija uvodi pogreške → utječe na konvergenciju

Prednosti

- Veća točnost nakon kvantizacije
- Model se bolje prilagođava niskoj preciznosti

Nedostaci

- Potrebno ponovno treniranje
- Veći računalni trošak

KVANTIZACIJA NAKON UČENJA

PTQ (Post Training Quantization)

- Kvantizacija se primjenjuje nakon treniranja
- Nema potrebe za ponovnim treniranjem
- **Kako funkcionira?** Koristi kalibracijske podatke za određivanje parametara
- **Ključna ideja?** PTQ je brži, ali QAT daje bolje rezultate

Prednosti

- Brza i jednostavna metoda
- Niski računalni troškovi
- Može raditi s malo označenih podataka

Nedostaci

- Manja točnost u odnosu na QAT
- Osjetljiva na vrlo nisku preciznost

LOW-RANK DECOMPOSITION (1/3)

- Aproksimacija matrice težina pomoću **matrice niskog ranga**
- **Cilj:** smanjenje veličine modela (kompresija)
- Ideja: smanjiti broj parametara bez velikog gubitka točnosti
- Postiže **$\sim 3\times$ kompresiju** u fully-connected slojevima
- Ne ubrzava značajno CNN: većina operacija u **konvolucijskim slojevima**

LOW-RANK DECOMPOSITION (2/3)

- Konvolucijski filtri = **tenzori (više dimenzija)**
- Koristi se **dekompozicija matrica i tenzora**
- Filtri se razlažu na **jednostavnije komponente**
- Primjena: DCT transformacije, separabilni filtri,...
- Rezultat: manje parametara, brže izvođenje (u nekim slučajevima)




Figure 3. Kernel approximation of low-rank decomposition matrix.

LOW-RANK DECOMPOSITION (3/3)

Prednosti

- Dobra kompresija modela
- Smanjuje memorijske zahtjeve
- Ubrzanje (do $\sim 4.5\times$ u nekim radovima)

Nedostaci

- Pad točnosti ($\sim 1\%$)
- Složena implementacija
- Radi se **po slojevima (nije globalno)**

Dodatan problem: moderne mreže koriste **1×1 konvolucije** → **slabiji efekt**

KNOWLEDGE DISTILLATION (1/3)

- **Arhitektura:** učitelj – student
- **Učitelj:** velik, već treniran model
- **Student:** manji, jednostavniji model
- **Cilj:** student postiže **slične performanse uz manju veličinu**
- **Važno za:** mobilne uređaje (manje memorije i snage)

KNOWLEDGE DISTILLATION (2/3)

- Student **oponaša učitelja**
- **Uči iz:** izlaza (predikcija), feature-a (značajki) i odnosa između slojeva
- **Ključ:** prijenos znanja iz velikog modela u mali
- Distilacija se može provesti na različite načine

KNOWLEDGE DISTILLATION (3/3)

1. Response-based:

koristi **izlaz modela (softmax)**

student kopira predikcije učitelja

2. Feature-based:

koristi **srednje slojeve (feature mape)**

student uči reprezentacije

3. Relation-based:

uči **odnose između feature-a**

koristi korelacije i strukturu podataka




Figure 6. (a) The generic response-based knowledge distillation. (b) The generic feature-based knowledge distillation. (c) The generic instance-relation-based knowledge distillation.

LIGHTWEIGHT MODEL DESIGN

- **Cilj** – Dizajnirati učinkovitu arhitekturu od nule kako bi se smanjio broj parametara i računalna složenost
- **Inovacija** – zamjena standardne konvolucije s jeftinijim operacijama
- **Primjeri** – SqueezeNet, MobileNet, ShuffleNet



Figure 1. MobileNet models can be applied to various recognition tasks for efficient on device intelligence.

KLJUČNI MODELI

Model	Methods
SqueezeNet	• 1x1 konvolucija umjesto 3x3 konvolucije • Downsampling operacija
SqueezeNext	• Low-rank separable konvolucija
MobileNetV1	• Depthwise separable konvolucija
MobileNetV2	• Smanjenje upotrebe 1x1 konvolucije • Linear bottleneck struktura
ShuffleNetV1	• 1x1 grupna konvolucija • Channel shuffle • Dizajniran za mobilne uređaje
ShuffleNetV2	• 1x1 dense konvolucija • Channel segmentation

NEURAL ARCHITECTURE SEARCH

- **Problem** – Ručno dizajnirane mreže je sporo i zahtjeva stručnost
- **NAS** – Automatska pretraga optimalne mrežne arhitekture
- **Optimizira** – točnost i brzinu za određeni uređaj
- **Primjeri** – MnasNet, FBNet, RegNet




Figure 7: **MnasNet-A1 Architecture** – (a) is a representative model selected from Table 1; (b) - (d) are a few corresponding layer structures. *MBConv* denotes mobile inverted bottleneck conv, *DWConv* denotes depthwise conv, *k3x3/k5x5* denotes kernel size, *BN* is batch norm, *HxWxF* denotes tensor shape (height, width, depth), and $\times 1/2/3/4$ denotes the number of repeated layers within the block.

KLJUČNI MODELI

MnasNet

- Točnost i latency na mobilnom uređaju
- Hijerarhijski search space

FBNet

- Kombinirao diferencijalni NAS (DNAS) i ograničenja resursa

FBNetV2

- Dodaje pretragu po kanalima i ulaznoj rezoluciji

FBNetV3

- Koristi predviđanje točnosti za brzo pretraživanje strukture mreže

EfficientNet


- Istovremeno skaliranje dubine, širine i rezolucije

RegNet


- Kombinira prednosti ručno dizajniranih mreža i NAS pristupa

ZAKLJUČAK

- **Neuronska Mreža** – Postala dominantni algoritam za zadatke računalnog vida
- **Treniranje** – Zahtjeva snažne hardverske resurse
- **Kompresija** – Značajno smanjuje veličinu modela, poboljšava brzinu zaključivanja
- **Nedostatci** – Prekomjerno prilagođavanje modela, gubitak točnosti i stabilnosti



?? DISKUSIJA ??



HVALA NA PAŽNJI!